

Contents

kb2-web vs 参考方案对比评估报告 — Codex 版

一、项目总览	1
二、项目差异对比	1
三、实践参考 (kb2-web 可借鉴参考方案的要点)	3
四、优化提升建议	4
附录A: 数据快照	4
附录B: 术语对照表	4

kb2-web vs 参考方案对比评估报告 — Codex 版

评估日期: 2026-07-07 15:00 评估对象: 方案A (参考方案 等保POC概念设计) vs 方案B (kb2-web 知识库V2)
评估工具: Codex CLI (OpenAI) , delegate_task 子代理模式 数据采集: 实时 DB 快照 + Git 历史 + 服务状态 + 代码审计

一、项目总览

维度	参考方案	kb2-web 实际
定位	等保测评机构本地知识库	通用政务信息化知识库 V2
技术栈	POC/MVP (4-6周)	生产系统 (约6个月迭代)
状态	PostgreSQL + pgvector + PgFTS + 本地模型 + FastAPI	SQLite + Hindsight 向量引擎 + DeepSeek + SiliconFlow
迭代阶段	文档方案, 未实现	系统运行中 (uvicorn PID 1560539) , 45MB SQLite DB
核心设计原则	规划中 (POC→MVP→生产)	T0/T1/T2 三轮精度调优、OKF 生命周期、CI 每日回归
	本地部署优先、数据治理先于模型、检索优先于检索管道完善来源卡片 + JWT RBAC + 66题测试集	

二、项目差异对比

2.1 架构层级对比

维度	参考方案	kb2-web 实际	差距分析
后端框架	FastAPI/Spring Boot (建议)	FastAPI (已实现)	kb2-web 已选定并运行
主数据库	PostgreSQL (推荐)	SQLite 45MB	参考方案更合理——SQLite 无并发写扩展能力
向量存储	pgvector (与 PG 集成)	Hindsight 独立引擎(:8888)	各有利弊
全文检索	PostgreSQL FTS	BM25Okapi (内存索引, 10min TTL)	kb2-web 更快但内存压力大
文档解析	本地 PDF/Word/Excel 工具	MinerU API (云端)	参考方案更符合”数据不出域”
Embedding	本地中文 Embedding 模型	text-embedding-3-small via API	参考方案数据安全性更高
Reranker	可选本地 Reranker	BGE-Reranker-v2-M3 + 5种模式	kb2-web 更丰富但依赖云端

维度	参考方案	kb2-web 实际	差距分析
大模型 缓存 多租户/多库	本地/内网模型 未提及 项目级权限隔离	DeepSeek v4 flash via API L1精确+L2语义+BM25内存缓存 11 Bank + 7活跃HS Bank	参考方案更安全 kb2-web 有完整双层缓存 kb2-web 多领域知识组织成熟
前端 审计日志	Vue/React（建议） PostgreSQL 审计表+日志文件	Vue3+TypeScript（11视图页面） 无权侧审计日志	kb2-web 完整 SPA 参考方案规划更完整

2.2 数据模型对比

维度	参考方案	kb2-web 实际
文档模型	文档编号、版本、密级、项目、等级、适用范围、审批状态	表：doc_id/title/bank/searchable/OKF全字段
切片模型	语义完整小片段+来源上下文	ParentChunk 分层切片（parent-child两级）+ chunk_count
知识组织	标准条款、测评项、问题、整改建议结构化	Concepts(3809) + SynonymMap(158) + KGTriple(45) + Contradictions(2029)
版本管理	文档版本、审批状态	version + supersedes/superseded_by双链 + stale检测
缓存 权限 同义词	未提及 用户/角色/项目/密级/使用范围 未明确提及	query_cache表(4条) + L1/L2双重缓存 User表 + admin/viewer两级 + JWT synonym_map(158条) + expand_query_synonyms

2.3 检索管线对比（核心差异）

维度	参考方案	kb2-web 实际
召回策略	全文检索+向量检索（pgvector）	三路召回：Hindsight语义+BM25关键词+取费表SQL+C1-StdBoost
融合策略 重排序	未详细说明 未提及	RRF融合(k=60) + tiebreaker sort 5种rerank模式：LLM/multidim/confidence/freshness/cross-encoder
查询优化 领域路由 拒答机制	未提及 按项目/密级过滤 应拒答越权/无答案内容	查询分解+同义词扩展+金额层级展开+标准编号归一化+D9 11 Bank分流+domain_routing 未实现拒答机制

2.4 数据治理对比

维度	参考方案	kb2-web 实际
文档总量	未指定	303篇（285active+18superseded）
切片总量	未指定	4,383 parent_chunks + ~29,297 Hindsight chunks
质量门禁 上传管线 脱敏	质量复核概念 语料登记→脱敏复核→解析→结构化 识别客户/IP/账号/漏洞等敏感内容	G1/G2/G3三级质量门禁+quality_gate_log 此阶段API上传发布审核(5条)+MinerU解析+chunking+concept
知识过期管理	保留期限+销毁要求	无脱敏实现 stale_detection服务+置信度衰减
文档来源	标准/模板/质控规则/问题/整改建议	manual(192)/v1_migration(78)/xhs(30)/v1_backfill(3)

2.5 安全与权限对比

维度	参考方案	kb2-web 实际
认证	机构现有SSO/RBAC或本地RBAC	JWT双通道+HTTPBearer
角色	多级角色（用户/角色/项目）	admin/viewer两级
内容级权限	按密级、使用范围、项目过滤	未实现
审计日志	PostgreSQL审计表+日志文件	无审计日志功能
拒答	越权检索/无答案时拒答	未实现拒答机制
API安全	未详细说明	CORS全开放(allow_origins=[“*”])+JWT+role-based router

2.6 评估验证体系对比

维度	参考方案	kb2-web 实际
测试方法论	未提及	66题LLM-Judge测试集+CI每日回归+趋势检测
回归验证	未提及	GitHub Actions自动回归+cron调度
过拒分析	未提及	3轮CC过拒审查+overrejection_test.py
精度调优	未提及	T0/T1/T2三轮调优+多维rerank权重调参
测试文件	未提及	32个测试文件
代码行数	设计文档	25,227行后端代码

三、实践参考 (kb2-web 可借鉴参考方案的要点)

3.1 安全合规方向 — P0

借鉴要点	价值	落地建议
内容级权限模型	高	Document表增加security_level字段，检索时追加SQL过滤
审计日志	高	建立audit_log表，记录每次检索和回答生成
拒答机制	中高	增加confidence threshold检查，低于阈值返回拒答
脱敏管线	高	upload流程中集成脱敏模块（IP/手机号/身份证正则替换）

3.2 数据治理方向 — P1

借鉴要点	价值	落地建议
语料登记与审批	中	upload_tasks表增加approval_status字段+审批API
密级与保留期限	中	Document表增加retention_date与现有stale_detection
数据补齐	中	为249个无摘要的概念批处理补齐摘要

3.3 架构扩展方向 — P1/P2

借鉴要点	价值	落地建议
PostgreSQL迁移	中高	迁移至PG+pgvector替代Hindsight
本地模型部署	中	部署本地vLLM/Ollama+bge-m3
内网部署文档	中	Docker Compose+无外网配置+模型镜像

四、优化提升建议

P0 — 紧急（安全合规）

编号	建议	工时
P0-1	实现拒答机制（置信度阈值检查）	4h
P0-2	实现检索审计日志（audit_log表+查询API）	8h
P0-3	加固CORS配置（明确前端地址）	1h
P0-4	JWT Secret生产环境轮换	0.5h

P1 — 重要（功能完善）

编号	建议	工时
P1-1	内容级权限过滤（security_level字段+检索过滤）	12h
P1-2	补齐概念摘要（249条无摘要概念）	2h
P1-3	PostgreSQL迁移评估报告	8h
P1-4	上传审批流程（G2门禁后approval_status）	8h
P1-5	同义词管理前端UI	6h

P2 — 长期（架构优化）

编号	建议	工时
P2-1	脱敏管线（IP/身份证/手机号正则替换）	16h
P2-2	本地模型部署（vLLM/Ollama+bge-m3）	24h
P2-3	多假设生成策略增强（5种视角）	4h
P2-4	GraphRAG探索（利用45条kg_triples+2029条contradiction）	16h
P2-5	性能基准测试	4h
P2-6	SSO集成（OAuth2/OIDC）	16h

附录A：数据快照

服务状态：kb-web v2.0.0, :3027, uvicorn PID 1560539, Hindsight :8888 healthy

数据库（45MB SQLite）： - documents: 303 (285 active + 18 superseded) - parent_chunks: 4,383 - concepts: 3,809 (3,560有摘要, 93.5%) - concept_contradictions: 2,029 - synonym_map: 158 - kg_triples: 45 - query_cache: 4 - users: 2 (1 admin + 1 viewer)

文档分布：standards(174)/general(72)/business(21)/industry_docs(15)/xhs(10)/project_docs(6)/methodology(2)/tech_g

检索参数：top_k=20, RRF k=60, rerank后返回15, chunk_size=800, overlap=120, BM10 TTL=10min, L1 cache=2000条, L2 cache阈值0.82, cache TTL=24h

最近提交（当日3个）： - cross-encoder reranker (BGE-Reranker-v2-M3, ~0.3s/query) - C1-StdBoost (doc_facts按published - D9 history anchor (历史锚点术语注入)

后端代码：123 Python文件, 25,227行, 12个端点模块, 25个服务模块, 32个测试文件

附录B：术语对照表

术语	说明
Hindsight Bank	独立向量检索引擎，基于Bank隔离存储 知识库领域分区，独立HS Bank和BM25索引

术语	说明
OKF	知识组织框架 (concept_id/domain/status/version链)
RRF	倒数排序融合 (Reciprocal Rank Fusion)
C1-StdBoost	标准编号精确匹配增强
SourceCard	来源卡片组件
LLM-Judge	LLM作为评估者评分
Quality Gates	G1格式/G2完整性/G3一致性
MinerU	云端PDF解析服务
SiliconFlow	API服务商 (Embedding+Reranker)